

Esercizio Dataiku: Previsione della Domanda con Reti Neurali — Versione Aggiornata

1. Introduzione e Obiettivi dell'Esercitazione

Questa esercitazione pratica ti guiderà nella costruzione di un modello di **previsione della domanda** utilizzando **Dataiku DSS** (Data Science Studio). Applicheremo i concetti di reti neurali e forward propagation appresi nelle lezioni di Andrew Ng per risolvere un problema di business reale: prevedere se un nuovo prodotto diventerà un best-seller.

Obiettivi di apprendimento

1. **Applicare lo scenario Demand Prediction** in un ambiente no-code — collegando prezzo, marketing e qualità ai concetti di accessibilità, consapevolezza e qualità percepita.
2. **Confrontare l'approccio visuale (Dataiku) con l'approccio programmatico (TensorFlow/Keras)** — capire vantaggi e limiti di ciascuno.
3. **Interpretare i pesi e le feature importance** — collegandoli ai neuroni nascosti che hai implementato manualmente nei Notebook
4. **Sperimentare con l'architettura della rete** — variare layer e neuroni e osservare l'impatto sulle performance.
5. **Comprendere il flusso end-to-end** di un progetto ML in ambiente enterprise.

-

2. Descrizione del Dataset: 'Product Demand'

Utilizzeremo un dataset sintetico chiamato `product_demand.csv` che contiene informazioni su vari prodotti e la loro performance di vendita. L'obiettivo è prevedere la colonna `is_bestseller` (1 se il prodotto è un best-seller, 0 altrimenti).

Collegamento con il Notebook 1

Nel Notebook 1 hai lavorato con un dataset simile (prezzo, spedizione, marketing, qualità) e hai visto come una rete neurale impara automaticamente le feature intermedie (accessibilità, consapevolezza, qualità percepita). Qui userai un dataset più ricco con feature aggiuntive.

Caratteristiche del dataset:

Colonna	Descrizione	Tipo	Collegamento con Ng
product_id	Identificativo unico del prodotto	Stringa	—
price	Prezzo di vendita (€)	Numerico	→ Accessibilità
shipping_cost	Costo di spedizione (€)	Numerico	→ Accessibilità
marketing_budget	Budget marketing (€)	Numerico	→ Consapevolezza
material_quality	Qualità del materiale (1-10)	Numerico	→ Qualità Percepita
category	Categoria prodotto	Stringa	Feature aggiuntiva
season	Stagione di lancio	Stringa	Feature aggiuntiva
customer_reviews	Media recensioni positive	Numerico	→ Qualità Percepita
competition_level	Livello concorrenza (1-5)	Numerico	Feature aggiuntiva
is_bestseller	TARGET: 1 = best-seller	Booleano	Variabile da predire

Esempio di dati:

product_id	price	shipping_cost	marketing_budget	material_quality	category	season	customer_reviews	competition_level	is_bestseller
P001	29.99	4.50	1500	8	Apparel	Summer	4.2	3	1
P002	12.50	3.00	200	5	Electronics	Winter	3.1	4	0
P003	59.99	7.00	5000	9	Home	Fall	4.8	2	1

4. Istruzioni Passo-Passo in Dataiku DSS

Segui attentamente questi passaggi per completare l'esercitazione.

4.1. Creazione del Progetto e Importazione del Dataset

1. **Avvia Dataiku DSS** e clicca su **+ New Project** → **Blank Project**.

- **Project Name:** Demand_Prediction_NN
- **Project Key:** DPNN
- Clicca **Create**.

2. **Importa il dataset `product_demand.csv`.**

- Nella homepage del progetto, clicca **+ New Dataset** → **Upload your files**.
- Trascina e rilascia il file `product_demand.csv` o naviga per selezionarlo.
- Clicca **Create** per creare il dataset.

3. **Esplora il dataset.**

- Clicca sul dataset `product_demand` per aprirlo.
- Nella sezione **Schema**, verifica che i tipi di dato siano stati inferiti correttamente.
- Nella sezione **Statistics**, osserva le distribuzioni delle colonne e i valori mancanti.

Collegamento con il Notebook 1: Ricordi le 4 feature del nostro dataset semplificato (prezzo, spedizione, marketing, qualità)? Qui abbiamo le stesse

feature più alcune aggiuntive. La rete neurale dovrà imparare le stesse relazioni che hai esplorato manualmente.

4.2. Preparazione dei Dati (Data Preparation)

1. Crea un nuovo Preparation Recipe.

- Dal dataset `product_demand`, clicca `+ Recipe` → `Preparation`.
- Lascia il nome di default per l'output dataset (es. `product_demand_prepared`) e clicca `Create`.

2. Pulisci e trasforma i dati.

- **Rimuovi la colonna `product_id`:** Non è utile per il modello. Seleziona la colonna `product_id`, clicca `Delete`.
- **Gestisci le variabili categoriche (`category`, `season`):** Applica l'encoding One-Hot.
 - Seleziona la colonna `category`, clicca `Processors` → `One-hot encode categorical` → `Apply`.
 - Ripeti per la colonna `season`.
- **Normalizza le variabili numeriche:** È fondamentale per le reti neurali.
 - Seleziona tutte le colonne numeriche (escluse quelle create dall'one-hot encoding e `is_bestseller`).
 - Utilizza la Recipe Window, calcola il min, max e poi normalizza le variabili numeriche.

3. Esegui le Recipe.

- Clicca `Run` in alto a destra per eseguire il recipe e creare il dataset preparato.
-

4.3. Analisi Esplorativa dei Dati (EDA)

Prima di costruire il modello, visualizziamo i dati preparati.

1. Crea un nuovo Analysis.

- Dal dataset `product_demand_prepared`, clicca + **Analysis** → **Visual Analysis** → **Create**.

2. **Crea grafici rilevanti** per verificare le ipotesi dello scenario Demand Prediction:

Grafico	Cosa cercare	Collegamento con Ng
Box plot: <code>price</code> vs <code>is_bestseller</code>	I best-seller hanno prezzi più bassi?	→ Accessibilità
Box plot: <code>marketing_budget</code> vs <code>is_bestseller</code>	I best-seller hanno più marketing?	→ Consapevolezza
Box plot: <code>material_quality</code> vs <code>is_bestseller</code>	I best-seller hanno qualità più alta?	→ Qualità Percepita
Scatter: <code>price</code> vs <code>marketing_budget</code> , colorato per <code>is_bestseller</code>	C'è una regione di decisione?	→ Regione di decisione (Notebook 2)
Distribuzione di <code>is_bestseller</code>	Il dataset è bilanciato?	→ Importanza per la valutazione

Domanda di riflessione: I pattern che osservi nei grafici sono coerenti con l'intuizione di business che hai sviluppato nel Notebook 1? I prodotti con prezzo basso + alto marketing + alta qualità tendono ad essere best-seller?

4.4. Creazione e Addestramento del Modello di Rete Neurale

Ora costruiremo il modello di rete neurale.

1. **Crea un nuovo Lab per il Machine Learning.**

- Dal dataset `product_demand_prepared`, clicca + **Lab** → **AutoML** → **Prediction** → **Create**.

- Seleziona **is_bestseller** come variabile target.
- Clicca **Create**.

2. Configura il modello di Rete Neurale.

- Nella sezione **Models**, clicca **+ Add Model → Deep Learning → Neural Network**.
- **Architettura della rete** — qui applicherai i concetti dei Notebook 1-4:

Layer	Neuroni	Attivazione	Perché
Input	Automatico	—	Dataiku lo gestisce
Hidden 1	16	ReLU (o Sigmoid)	Come il layer nascosto del Notebook 1 (accessibilità, consapevolezza, qualità)
Hidden 2	8	ReLU (o Sigmoid)	Combinazione delle feature intermedie
Output	1	Sigmoid	Probabilità di best-seller (come nel Notebook 3)

- **Parametri di training:**
 - **Epochs:** 50 (o 100 per risultati migliori)
 - **Batch size:** 32
- Clicca **Train**.

3. Addestra altri modelli (per confronto).

- Aggiungi e addestra anche un modello **Logistic Regression** e un **Random Forest** per confrontare le performance.
 -
-

4.5. Valutazione e Interpretazione del Modello

Dopo l'addestramento, valuteremo i modelli.

1. Analizza le performance del modello di Rete Neurale.

- Clicca sul modello di Rete Neurale appena addestrato.
- Nella sezione **Performance**, osserva:
 - **AUC**: Area Under the ROC Curve (metrica chiave per classificazione sbilanciata).
 - **Accuracy**: Accuratezza generale.
 - **Confusion Matrix**: Matrice di confusione per vedere veri positivi, falsi positivi, ecc.
 - **ROC Curve**: Curva ROC per visualizzare il trade-off tra True Positive Rate e False Positive Rate.

2. Confronta i modelli.

- Torna alla lista dei modelli e clicca **Compare** per confrontare la Rete Neurale con Logistic Regression e Random Forest.

Modello	Cosa rappresenta	Collegamento con i materiali
Logistic Regression	Un singolo neurone	ITS_reti_neurali_intro_xor_problem.ipynb
Random Forest	Ensemble di alberi	ITS_ensemble_learning.ipynb
Neural Network	Rete multi-layer	Notebook 1-4 di questo corso

3. Interpreta il modello (Feature Importance).

- Per il modello di Rete Neurale, vai alla sezione **Subpopulation Analysis** o **Feature Importance**.
- Quali sono le feature più importanti per prevedere se un prodotto è un best-seller?

Collegamento con il Notebook 1: Nel Notebook 1 hai visto che i neuroni nascosti imparano automaticamente concetti come "accessibilità" (da prezzo e spedizione), "consapevolezza" (da marketing) e "qualità percepita" (da qualità e prezzo). La

Feature Importance di Dataiku dovrebbe riflettere questi stessi pattern: le feature legate a prezzo, marketing e qualità dovrebbero essere le più importanti.

4.6. Sperimentazione con l'Architettura (NUOVO)

Questo passaggio è **nuovo** rispetto all'esercitazione originale

1. **Sperimenta con diverse architetture** e osserva l'impatto sulle performance:

Esperimento	Architettura	Cosa osservare
A (Baseline)	16 → 8 → 1	Performance di riferimento
B (Più profonda)	32 → 16 → 8 → 1	Migliora con più layer?
C (Più larga)	64 → 32 → 1	Migliora con più neuroni?
D (Minima)	3 → 1	Come il Notebook 1 (3 neuroni = accessibilità, consapevolezza, qualità)

2. **Per ogni esperimento**, annota:

- AUC sul test set
- Tempo di addestramento
- Numero totale di parametri (calcolalo manualmente come nel Notebook 2!)

Esercizio di calcolo: Per l'architettura D (3 → 1), calcola manualmente il numero di parametri:

- Layer nascosto: $(n_{\text{feature}} \times 3) + 3$ bias
- Layer output: $(3 \times 1) + 1$ bias
- Totale: ?

Confronta con il risultato di `model.summary()` nel Notebook 2.

3. **Domanda chiave:** L'architettura D (con solo 3 neuroni nascosti) riesce a catturare i 3 concetti (accessibilità, consapevolezza, qualità percepita)? Le performance sono significativamente peggiori rispetto alle architetture più grandi?

4.7. Deployment del Modello (Scoring)

Una volta soddisfatti delle performance, possiamo usare il modello per fare predizioni su nuovi dati.

1. Deploy del modello per lo scoring.

- Dal modello migliore, clicca **Deploy** → **Deploy to Flow** → **Create**.
- Questo creerà un nuovo Recipe nel Flow che userà il modello per fare predizioni.

2. Esegui il Recipe di Scoring.

- Nel Flow, vedrai un nuovo Recipe che prende il dataset preparato e produce un dataset con le predizioni.
- Esegui questo Recipe.

3. Esplora le predizioni.

- Apri il dataset di output del Recipe di Scoring. Dovresti vedere nuove colonne come **prediction_is_bestseller** e **probability_is_bestseller**.
-