

Guida Pratica al Machine Learning con Dataiku

ITS febbraio 2026

Introduzione

Questa guida è pensata per accompagnare gli studenti in un percorso pratico di apprendimento della piattaforma Dataiku DSS (Data Science Studio). Attraverso cinque progetti a scelta, gli studenti impareranno a gestire l'intero ciclo di vita di un progetto di machine learning: dall'importazione dei dati alla creazione di modelli predittivi, fino alla loro interpretazione e messa in produzione.

I progetti coprono diverse aree di applicazione e tipologie di modelli, fornendo una visione completa delle potenzialità di Dataiku in contesti aziendali reali.

Progetto 1: Previsione del Costo Medio dei Sinistri Sanitari

1. Panoramica del Progetto

Settore: Assicurativo/Sanitario

Tipo di Modello: Regressione

1.1. Scenario Aziendale

Una compagnia di assicurazioni sanitarie desidera prevedere il costo medio annuo dei sinistri per ogni assicurato. Questa previsione è fondamentale per calibrare i premi assicurativi in modo più accurato, identificare i clienti che potrebbero generare costi elevati e, in generale, ottimizzare la strategia di tariffazione e gestione del rischio.

Decisioni Supportate dal Modello:

- Definizione dei premi assicurativi.
- Calibrazione delle franchigie.
- Segmentazione della clientela per campagne di prevenzione o gestione personalizzata.

Valore per il Business:

- **Riduzione del rischio tecnico:** Migliorando l'accuratezza delle previsioni, la compagnia può ridurre il rischio di perdite dovute a una sottostima dei costi futuri.
- **Premi più competitivi e equi:** Una tariffazione basata sul rischio individuale permette di offrire premi più vantaggiosi ai clienti a basso rischio e di coprire adeguatamente i clienti ad alto rischio.

1.2. Dataset

Per questo progetto, utilizzeremo il dataset "Medical Cost Personal Dataset" disponibile su Kaggle.?

- **Link:** <https://www.kaggle.com/datasets/mirichoi0218/insurance>
- **Caratteristiche:** Il dataset contiene circa 1.338 osservazioni e 7 variabili.

Variabili Principali:

Variabile	Descrizione
<u>age</u>	Età dell'assicurato (numerica)
<u>sex</u>	Sesso dell'assicurato (categorica: 'male', 'female')
<u>bmi</u>	Indice di massa corporea (numerica)
<u>children</u>	Numero di figli a carico (numerica)
<u>smoker</u>	Indicatore di fumo (categorica: 'yes', 'no')
<u>region</u>	Area geografica di residenza (categorica)
<u>charges</u>	Variabile Target: Costo sanitario annuo fatturato dall'assicurazione (numerica)

2. Fase 1: Dal Dato Grezzo al Primo Modello

Obiettivo: In questa fase, importeremo i dati, li puliremo, creeremo nuove feature e addestreremo i nostri primi modelli di regressione.

2.1. Importazione del Dataset in Dataiku

- 1 **Creare un Nuovo Progetto:** Accedere a Dataiku DSS, andare alla homepage e cliccare su "+ New Project" > "DSS Tutorial" > "Quick Start" > "Create". Assegnare un nome al progetto, ad esempio Previsione_Costi_Sanitari.
- 2 **Importare il Dataset:**
 - Scaricare il file insurance.csv dal link di Kaggle.
 - Nel Flow del progetto, cliccare su "+ IMPORT YOUR FIRST DATASET".
 - Selezionare "Upload your files" e caricare il file insurance.csv.
 - Dataiku rileverà automaticamente il formato e le colonne. Verificare che l'anteprima sia corretta e cliccare su "CREATE". Assegnare al dataset il nome insurance_raw.

2.2. Esplorazione e Analisi dei Dati (EDA)

Prima di ogni operazione di modifica, è fondamentale esplorare i dati.

- 3 **Aprire il Dataset:** Cliccare sul dataset insurance_raw nel Flow per aprirlo.
- 4 **Utilizzare la Funzione "Analyze":**
 - Selezionare una colonna (es. age) e cliccare sulla freccia del menu a tendina, poi su "Analyze".
 - Dataiku mostrerà un'analisi univariata della colonna, con statistiche descrittive e un istogramma della distribuzione.
 - **Esercizio:** Analizzare le colonne age, bmi e charges. Quali sono le loro distribuzioni? Ci sono valori anomali evidenti?

2.3. Pulizia dei Dati (Data Cleaning)

Creeremo ora una "ricetta" di preparazione per pulire i dati.

- 5 **Creare una Prepare Recipe:**
 - Dal dataset insurance_raw, cliccare sul pannello a destra e selezionare "Prepare" dal menu "Actions".
 - Lasciare il nome di default per l'output (insurance_prepared) e cliccare su "CREATE RECIPE".
- 6 **Gestire i Valori Mancanti:**
 - Nella vista della ricetta, Dataiku mostra la qualità dei dati per ogni colonna. Se ci fossero valori mancanti, si potrebbe cliccare sulla barra della qualità della colonna e scegliere un'azione, come "Remove rows where cell is empty" o "Impute with mean/median". Per questo dataset, non dovrebbero esserci valori mancanti significativi.
- 7 **Convertire le Variabili Categoricali:**
 - I modelli di machine learning richiedono input numerici. Le colonne sex, smoker e region sono testuali.
 - Cliccare su "+ ADD A NEW STEP" e cercare "Dummy-encode variables".

- Selezionare le colonne sex, smoker e region. Questa operazione creerà nuove colonne binarie (0/1) per ogni categoria.
- 8 **Controllo Outlier per bmi:**
- Dall'analisi precedente, si potrebbe notare qualche valore di bmi particolarmente alto o basso. Un modo per gestirli è la "Winsorizzazione".
 - Selezionare la colonna bmi e impostare i quantili per il clipping (es. tagliare i valori al di sotto del 1° percentile e al di sopra del 99° percentile).
- 9 **Eseguire la Ricetta:** Cliccare su "RUN" in basso a sinistra per applicare le trasformazioni e creare il nuovo dataset insurance_prepared.

2.4. Creazione di Nuove Feature (Feature Engineering)

Arricchiamo il nostro dataset con nuove variabili che potrebbero aiutare il modello.

- 10 **Continuare la Prepare Recipe (o crearne una nuova):** Partendo dal dataset insurance_prepared, creare una nuova Prepare Recipe. Chiamare l'output insurance_features.
- 11 **Creare Gruppi di Età (age_group):**
- Usare la funzione "Bin a numerical variable".
 - Selezionare la colonna age e definire le fasce (es. 18-30, 31-45, 46-60, 60+).
- 12 **Creare Classi di BMI (bmi_class):**
- Similmente, creare delle classi per bmi (es. Sottopeso, Normopeso, Sovrappeso, Obeso) basate sugli standard medici.
- 13 **Creare Flag Numerici:**
- Se non già fatto con il dummy encoding, trasformare smoker in un flag numerico (smoker_flag: 1 se 'yes', 0 se 'no').
 - Creare un flag has_children (1 se children > 0, 0 altrimenti) usando una formula: if(children > 0, 1, 0).
- 14 **Eseguire la Ricetta:** Cliccare su "RUN".

2.5. Creazione del Primo Modello di Regressione

- 15 **Dividere il Dataset:**
- Partendo da insurance_features, creare una "Split Recipe".
 - Dividere il dataset in due: insurance_train e insurance_test.
 - Impostare una divisione casuale (random dispatch) con un rapporto 70/30 (70% per il training, 30% per il test).
- 16 **Accedere al Laboratorio di Modellazione:**
- Cliccare sul dataset insurance_train e, dal pannello "Actions", selezionare "Lab".
 - Scegliere "AutoML Prediction".
 - Selezionare charges come variabile target.
- 17 **Addestrare i Modelli:**

- Dataiku proporrà una serie di modelli. Per questo esercizio, assicurarsi di selezionare "Random Forest" e "Linear Regression".
- Cliccare su "TRAIN". Dataiku addestrerà i modelli sul set di training e li valuterà sul set di test (che internamente crea dalla porzione di training).

3. Fase 2: Ottimizzazione e Interpretazione del Modello

Obiettivo: In questa fase, miglioreremo le performance del nostro modello, impareremo a interpretarne i risultati e lo useremo per fare previsioni su nuovi dati.

3.1. Analisi e Miglioramento del Modello

18 Analizzare i Risultati:

- Una volta completato l'addestramento, Dataiku mostra una schermata di riepilogo con le performance dei modelli. La metrica principale per la regressione è solitamente la **R² (R-squared)**, che indica quanta parte della varianza della variabile target è spiegata dal modello. Un valore più alto è migliore.
- Confrontare la R² di Random Forest e Linear Regression. Quale performa meglio?

19 **Ottimizzazione degli Iperparametri (per Random Forest):

- Selezionare il modello Random Forest. Nel pannello dei risultati, navigare nella sezione "Hyperparameters".
- Dataiku permette di modificare parametri come il numero di alberi (Number of trees), la profondità massima (Max depth), etc.
- **Esercizio:** Provare a cambiare alcuni di questi parametri (es. aumentare il numero di alberi a 200) e ri-addestrare il modello. La performance migliora?

3.2. Interpretazione del Modello

Capire *perché* un modello fa certe previsioni è tanto importante quanto la sua accuratezza.

20 Feature Importance:

- Nella schermata dei risultati del modello, andare alla sezione "Feature Importance".
- Questo grafico mostra quali variabili hanno il maggior peso nelle decisioni del modello.
- **Domanda:** Quali sono le 3 variabili più importanti per prevedere i costi sanitari? (Probabilmente smoker, bmi e age).

21 Partial Dependence Plots (PDP):

- Questa visualizzazione mostra l'effetto di una singola variabile sulla previsione, mantenendo costanti tutte le altre.
- Andare su "Partial Dependence Plots" e selezionare la variabile age.
- **Analisi:** Come cambia il costo previsto (charges) all'aumentare dell'età? La relazione è lineare?

22 Individual Explanations:

- Dataiku può spiegare la previsione per un singolo dato.
- Nella sezione "Individual Explanations", si possono vedere le previsioni per alcuni campioni del test set e quali feature hanno contribuito di più (in positivo o in negativo).
- **Esercizio:** Trovare un cliente con un costo previsto molto alto e analizzare la spiegazione. Quali fattori lo rendono un cliente "costoso"?

23 What-If Analysis:

- Questa potente funzione permette di creare scenari ipotetici.
- Andare su "What-if" e selezionare un cliente. Si possono modificare i valori delle sue feature per vedere come cambia la previsione.
- **Scenario:** Prendere un cliente non fumatore e cambiare il suo status in smoker = yes. Di quanto aumenta il costo previsto? E se si aumenta il suo bmi di 5 punti?

3.3. Fare Previsioni su Nuovi Dati

Ora useremo il nostro modello migliore per prevedere i costi per nuovi clienti.

24 Salvare il Modello:

- Tornare alla lista dei modelli, selezionare il migliore (es. Random Forest ottimizzato) e cliccare su "Deploy to Flow".
- Questo crea un "Saved Model" nel Flow, pronto per essere usato.

25 **Creare un Dataset Futuro (insurance_future_input):

- Creare un nuovo dataset manualmente ("DATASET" > "Manual").
- Creare le stesse colonne del dataset di training (age, sex, bmi, etc.).
- **Esercizio:** Inserire 10-20 righe di dati per clienti ipotetici, come da esempi nel documento originale.
 - *Cliente 1:* age = 45, bmi = 27, children = 2, smoker = yes, region = southwest
 - *Cliente 2:* age = 30, bmi = 22, children = 0, smoker = no, region = northeast

26 Applicare la Prediction Recipe:

- Cliccare sul "Saved Model" nel Flow e selezionare "Score" dal pannello "Actions".
- Come input, selezionare il dataset insurance_future_input.
- Chiamare l'output insurance_predictions e creare la ricetta.
- Eseguire la ricetta ("RUN").

27 Analizzare le Previsioni:

- Aprire il dataset insurance_predictions. Contrerà le colonne originali più una nuova colonna con la previsione del costo (charges_prediction).
- **Verifica:** Il cliente fumatore ha un costo previsto più alto dell'altro? I risultati sono in linea con le interpretazioni fatte in precedenza?

4. Consegna Finale

Per completare il progetto, gli studenti devono presentare:

- 28 **Un Flow di Dataiku funzionante:** Dall'importazione dei dati fino alle previsioni finali.
 - 29 **Il dataset insurance predictions:** Contenente le previsioni per i clienti futuri.
 - 30 **Una breve presentazione (poche slide) che riassume:**
 - Il problema di business.
 - Il modello scelto e le sue performance (R^2).
 - Le variabili più importanti (Feature Importance).
 - Un esempio di previsione e la sua interpretazione.
-

Progetto 2: Previsione del Rischio di Abbandono Clienti (Churn) nel Settore Telecom

1. Panoramica del Progetto

Settore: Telecomunicazioni

Tipo di Modello: Classificazione

1.1. Scenario Aziendale

Una società di telecomunicazioni (Telco) sta affrontando un problema comune nel settore: la perdita di clienti (churn). L'obiettivo è costruire un modello in grado di prevedere con anticipo quali clienti sono più propensi ad abbandonare il servizio. Questa informazione è cruciale per poter intervenire con azioni mirate.

Decisioni Supportate dal Modello:

- **Campagne di Retention:** Identificare i clienti a rischio per includerli in campagne di fidelizzazione personalizzate.
- **Sconti e Offerte Mirate:** Proporre sconti o upgrade del servizio ai clienti che mostrano un'alta probabilità di abbandono per incentivarli a rimanere.

Valore per il Business:

- **Riduzione del Tasso di Churn:** Mantenere i clienti esistenti è quasi sempre meno costoso che acquisirne di nuovi. Una riduzione anche piccola del tasso di churn può avere un impatto significativo sui ricavi e sulla stabilità del business.

1.2. Dataset

Il progetto si basa sul noto dataset "Telco Customer Churn", ampiamente utilizzato per problemi di classificazione.

- **Link:** <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
- **Caratteristiche:** Il dataset è ricco, con oltre 7.000 righe e più di 20 variabili che descrivono i clienti, i servizi sottoscritti e il loro stato contrattuale.

Variabili Principali:

Categoria	Variabili Esempio	Descrizione
Dati Demografici	<u>gender</u> , <u>SeniorCitizen</u> , <u>Partner</u>	Informazioni sul cliente.
Servizi Sottoscritti	<u>PhoneService</u> , <u>InternetService</u> , <u>OnlineSecurity</u>	Dettagli sui servizi attivi.
Dati Contabili	<u>tenure</u> , <u>Contract</u> , <u>MonthlyCharges</u> , <u>TotalCharges</u>	Anzianità del cliente, tipo di contratto e importi fatturati.
Variabile Target	<u>Churn</u>	Variabile Target: Indica se il cliente ha abbandonato il servizio (categoria: 'Yes', 'No').

2. Fase 1: Preparazione dei Dati e Primo Modello di Classificazione

Obiettivo: In questa fase, importeremo ed esploreremo il dataset, eseguiremo la pulizia e la preparazione necessarie e addestreremo un primo modello per prevedere il churn.

2.1. Importazione ed Esplorazione

Seguendo la stessa procedura del Progetto 1, create un nuovo progetto in Dataiku (es. Telco_Churn_Prediction) e importate il dataset WA_Fn-UseC_-Telco-Customer-Churn.csv, nominandolo telco_raw. Una volta importato, dedicate del tempo all'esplorazione. Utilizzate la funzione "Analyze" su colonne chiave come tenure (l'anzianità del cliente), Contract e la variabile target Churn per capire le distribuzioni e le relazioni iniziali.

2.2. Pulizia e Preparazione dei Dati

Create una "Prepare Recipe" partendo da telco_raw per generare un nuovo dataset telco_prepared. Durante questa fase, dovrete affrontare alcune sfide comuni.

- 31 **Gestione Valori Mancanti e Tipi di Dati:** La colonna TotalCharges, sebbene numerica, potrebbe essere interpretata come stringa a causa di spazi vuoti per i clienti nuovi (con tenure a 0). Questi spazi vuoti rappresentano valori mancanti. Dovrete prima convertirli in veri e propri "missing values" e poi imputarli, ad esempio con il

valore 0, poiché questi clienti non hanno ancora avuto addebiti totali.
Successivamente, assicuratevi che la colonna sia convertita in un tipo numerico.

- 32 **Encoding delle Variabili Categoricali:** Come nel progetto precedente, utilizzate lo step "Dummy-encode variables" per trasformare tutte le colonne di testo (es. Contract, InternetService) in variabili numeriche che il modello possa interpretare.

2.3. Feature Engineering

Create una seconda "Prepare Recipe" a partire da telco_prepared per generare telco_features. Qui creeremo nuove variabili per aiutare il modello a catturare meglio i pattern.

- **Raggruppamento della tenure:** Create una nuova colonna tenure_group raggruppando i valori di tenure in fasce (es. 0-12 mesi, 13-24 mesi, 25-48 mesi, >48 mesi). Questo può aiutare il modello a generalizzare meglio rispetto ai singoli valori di anzianità.
- **Discretizzazione dei Costi Mensili:** Similmente, create una colonna monthly_cost_bucket per raggruppare i clienti in fasce di spesa mensile (es. Basso, Medio, Alto).

2.4. Creazione del Modello di Classificazione

- 33 **Divisione del Dataset:** Utilizzate una "Split Recipe" su telco_features per creare i dataset telco_train e telco_test (es. con un rapporto 80/20).
- 34 **Addestramento del Modello:** Aprite il "Lab" dal dataset telco_train, scegliete "AutoML Prediction" e selezionate Churn come target. Dataiku riconoscerà che si tratta di un problema di classificazione (Yes/No). Assicuratevi di includere tra gli algoritmi la **Regressione Logistica** e il **Random Forest**. Avviate l'addestramento.

3. Fase 2: Interpretazione, Ottimizzazione e Previsione del Churn

Obiettivo: Analizzeremo le performance del modello, ne interpreteremo le previsioni e lo utilizzeremo per identificare i clienti a rischio in un nuovo set di dati.

3.1. Analisi e Ottimizzazione del Modello

Una volta terminato l'addestramento, analizzate i risultati. Per la classificazione, una metrica fondamentale è l'AUC (**Area Under the ROC Curve**). Un valore di AUC vicino a 1 indica un modello con un'ottima capacità di distinguere tra le due classi (clienti che fanno churn e clienti che non lo fanno).

- **Confronto Modelli:** Confrontate l'AUC dei modelli addestrati. Quale ha la performance migliore?
- **Matrice di Confusione e Soglia:** Analizzate la matrice di confusione. Questa tabella mostra i veri positivi, veri negativi, falsi positivi e falsi negativi. È possibile modificare la **soglia di probabilità** per ottimizzare il bilanciamento tra **precisione** (la percentuale di clienti previsti come cherner che lo sono davvero) e **recall** (la percentuale di veri cherner che il modello è riuscito a identificare). A seconda del

costo di un'azione di retention, l'azienda potrebbe preferire un modello con una recall più alta per non perdere nessun potenziale churmer, anche a costo di contattare qualche cliente che non avrebbe abbandonato.

3.2. Interpretazione del Modello

- 35 **Feature Importance:** Identificate le variabili più influenti. È probabile che Contract (i clienti con contratto mensile sono più volatili), tenure (i clienti più recenti sono più a rischio) e InternetService (tipo di connessione) siano tra le più importanti.
- 36 **Partial Dependence Plots:** Analizzate la relazione tra la probabilità di churn e la tenure. Si dovrebbe osservare che la probabilità diminuisce all'aumentare dell'anzianità del cliente.
- 37 **Individual Explanations:** Trovate un cliente con un'alta probabilità di churn e analizzate i fattori che contribuiscono a questa previsione.
- 38 **What-If Analysis:** Simulate uno scenario interessante. Prendete un cliente a rischio con un contratto Month-to-month e vedete come cambia la sua probabilità di churn se il suo contratto diventasse One year o Two year.

3.3. Previsioni su Nuovi Clienti

- 39 **Deploy e Score:** Salvate il modello migliore nel Flow e createne una versione "deployed". Create un dataset manuale telco_future_customers con alcuni profili di nuovi clienti (es. un cliente con tenure = 2, Contract = 'Month-to-month').
- 40 **Eseguire la Previsione:** Utilizzate la "Score Recipe" per applicare il modello al dataset futuro. L'output, telco_predictions, conterrà le colonne originali più la probabilità di churn (proba_Yes) e la previsione finale (prediction).

4. Consegna Finale

Come per il progetto precedente, la consegna consiste nel Flow funzionante, nel dataset con le previsioni e in una breve presentazione che illustri il processo, i risultati e le intuizioni di business ottenute.

Progetto 3: Previsione del Prezzo degli Immobili Residenziali

1. Panoramica del Progetto

Settore: Immobiliare

Tipo di Modello: Regressione

1.1. Scenario Aziendale

Un'agenzia immobiliare o un portale online vuole sviluppare un modello per prevedere il prezzo di vendita degli immobili residenziali. Questo strumento può essere utilizzato sia internamente, per aiutare gli agenti a definire un prezzo di mercato corretto, sia esternamente, come feature per gli utenti del sito che desiderano una stima del valore di un'abitazione.

Decisioni Supportate dal Modello:

- **Valutazione automatizzata (AVM - Automated Valuation Model):** Fornire stime rapide dei prezzi delle case.
- **Supporto alla decisione per agenti immobiliari:** Aiutare a definire il prezzo di listino ottimale.
- **Identificazione di immobili sottovalutati o sopravvalutati:** Supportare strategie di investimento.

Valore per il Business:

- **Efficienza:** Automatizzare un processo di valutazione che altrimenti richiederebbe tempo e competenze specifiche.
- **Trasparenza e Coinvolgimento:** Offrire un servizio a valore aggiunto ai clienti, aumentando il traffico e la fiducia nel portale/agenzia.

1.2. Dataset

Questo progetto utilizza il dataset "House Prices: Advanced Regression Techniques" di Kaggle, un classico per le competizioni di regressione.

- **Link:** <https://www.kaggle.com/c/house-prices-advanced-regression-techniques/data> (Nota: questo è un link a una competizione, il dataset si trova nella sezione "Data"). Potrebbe essere più semplice usare una versione già pulita come quella indicata nel documento originale: <https://www.kaggle.com/datasets/shree1992/housedata>
- **Caratteristiche:** Il dataset è molto ricco e complesso, con quasi 80 variabili che descrivono ogni aspetto di un'abitazione, dalla dimensione del lotto alla qualità delle finiture.

Variabili Principali:

Categoria	Variabili Esempio	Descrizione
Dimensioni	<u>GrLivArea</u> , <u>TotalBsmtSF</u> , <u>LotArea</u>	Metratura della zona giorno, del seminterrato, del lotto.
Qualità e Condizioni	<u>OverallQual</u> , <u>OverallCond</u> , <u>YearBuilt</u>	Valutazioni generali sulla qualità e condizione, anno di costruzione.

Categoria	Variabili Esempio	Descrizione
Caratteristiche	<u>BedroomAbvGr</u> , <u>FullBath</u> , <u>GarageCars</u>	Numero di camere, bagni, posti auto in garage.
Location	<u>Neighborhood</u>	Quartiere in cui si trova l'immobile.
Variabile Target	<u>SalePrice</u>	Variabile Target: Il prezzo di vendita finale dell'immobile.

2. Flusso di Lavoro in Dataiku

Data la complessità del dataset, con molte variabili e potenziali valori mancanti, la fase di preparazione sarà più intensiva rispetto ai progetti precedenti. La difficoltà è valutata 3/5 principalmente per la gestione delle numerose feature.

2.1. Preparazione dei Dati (house_clean e house_features)

- 41 **Importazione:** Importare il dataset in Dataiku e nominarlo house_raw.
- 42 **Gestione Estensiva dei Valori Mancanti:** Questo dataset ha valori mancanti in molte colonne. Per ognuna, è necessario adottare una strategia:
 - Per variabili numeriche come LotFrontage, l'imputazione con la media o la mediana del quartiere (Neighborhood) potrebbe essere una strategia efficace.
 - Per variabili categoriche come GarageType o BsmtQual, un valore mancante spesso significa l'assenza di quella caratteristica (es. nessun garage, nessun seminterrato). In questi casi, si può imputare con una nuova categoria, come "Nessuno".
- 43 **Feature Engineering:**
 - **Creazione di Feature Temporali:** Calcolare l'età della casa al momento della vendita (YrSold - YearBuilt).
 - **Combinazione di Feature:** Creare una variabile TotalSF sommando la superficie totale del seminterrato (TotalBsmtSF) e quella del primo e secondo piano (1stFlrSF, 2ndFlrSF).
 - **Trasformazioni Logaritmiche:** La variabile target SalePrice e alcune feature numeriche potrebbero avere una distribuzione asimmetrica (skewed). Applicare una trasformazione logaritmica ($\log(x+1)$) può aiutare i modelli lineari a performare meglio. Ricordarsi di applicare la trasformazione inversa alla fine per interpretare le previsioni.
- 44 **Encoding:** Utilizzare il dummy encoding per le variabili categoriche.

2.2. Modellazione e Interpretazione

- 45 **Split e Training:** Dividere il dataset (house_features) in house_train e house_test. Addestrare modelli di regressione come **Ridge Regression** (efficace quando ci sono

molte feature) e **Gradient Boosted Trees**, che spesso offrono performance molto elevate su dati tabulari.

46 **Valutazione:** La metrica principale per questa competizione è il **Root Mean Squared Logarithmic Error (RMSLE)**. In Dataiku, si può usare la **RMSE (Root Mean Squared Error)** sulla variabile SalePrice trasformata in logaritmo, che è concettualmente simile.

47 **Interpretazione:**

- **Feature Importance:** Quali sono le caratteristiche che più influenzano il prezzo di una casa? È probabile che OverallQual, GrLivArea e TotalSF siano in cima alla lista.
- **Analisi per Segmenti:** Analizzare le performance del modello per diversi quartieri (Neighborhood). Il modello è ugualmente accurato ovunque?

2.3. Previsione su Nuovi Immobili

Come nei progetti precedenti, salvare il modello migliore, creare un dataset house_future con le caratteristiche di alcune case simulate e utilizzare la "Score Recipe" per generare le previsioni di prezzo in house_predictions.

3. Consegna Finale

Il risultato finale sarà un flusso Dataiku completo in grado di prezzare nuovi immobili, accompagnato da una presentazione che spieghi le scelte di modellazione e le principali determinanti del prezzo scoperte attraverso l'analisi.

Progetto 4: Sistema di Previsione della Domanda di Camere d'Albergo

1. Panoramica del Progetto

Settore: Turismo/Ospitalità

Tipo di Modello: Classificazione

1.1. Scenario Aziendale

Un grande operatore turistico o una catena alberghiera vuole prevedere la probabilità che una richiesta di prenotazione si trasformi in una prenotazione confermata. L'obiettivo è

ottimizzare la strategia di prezzo (pricing dinamico) e la gestione della disponibilità delle camere.

Decisioni Supportate dal Modello:

- **Markup Dinamico:** Se la probabilità di prenotazione è alta, si può applicare un markup (ricarico) leggermente superiore. Se è bassa, si può offrire un piccolo sconto per incentivare la conferma.
- **Gestione della Disponibilità (Yield Management):** Gestire in modo più efficiente l'allocazione delle camere, soprattutto nei periodi di alta domanda.

Valore per il Business:

- **Aumento del Margine di Guadagno:** Ottimizzare i prezzi in tempo reale per massimizzare i ricavi per ogni camera disponibile.

1.2. Dataset

Il progetto utilizza un dataset molto ampio e dettagliato sulle prenotazioni alberghiere.

- **Link:** <https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand>
- **Caratteristiche:** Con quasi 120.000 righe e oltre 30 variabili, questo è il dataset più grande e complesso del corso.

Variabili Principali:

Categoria	Variabili Esempio	Descrizione
Dettagli Prenotazione	<u>lead_time</u> , <u>arrival_date_month</u> , <u>stays_in_weekend_nights</u>	Anticipo della prenotazione, mese di arrivo, notti nel weekend.
Dati Cliente	<u>market_segment</u> , <u>customer_type</u> , <u>country</u>	Canale di prenotazione, tipo di cliente, paese di origine.
Variabile Target	<u>is_canceled</u>	Variabile Target: Indica se la prenotazione è stata cancellata (1) o no (0).

Nota sulla Target: Il problema chiede di prevedere la *probabilità di prenotazione*. La variabile is_canceled indica la cancellazione. Possiamo creare una nuova variabile booking_confirmed che è l'inverso di is_canceled ($1 - is_canceled$) e usarla come target, oppure usare is_canceled e prevedere la probabilità della classe "0".

2. Flusso di Lavoro del Progetto

Questo progetto consolida tutte le competenze acquisite. La difficoltà (3/5) non risiede tanto in nuove tecniche, quanto nella gestione della scala dei dati e nella profondità dell'analisi richiesta.

2.1. Preparazione e Feature Engineering (bookings_clean, bookings_features)

- 48 **Gestione Date:** Come nel progetto delle serie storiche, sarà cruciale parsare correttamente le colonne relative alle date di arrivo (arrival_date_year, arrival_date_month, arrival_date_day_of_month).
- 49 **Creazione di Feature di Stagionalità:** Estrarre componenti come la stagione (inverno, primavera, estate, autunno) dal mese di arrivo.
- 50 **Creazione di Flag:** Creare un weekend_flag se la prenotazione include notti nel weekend.
- 51 **Raggruppamento di Categorie:** La variabile country ha troppe modalità distinte. Raggruppare i paesi meno frequenti in una categoria "Altro" può aiutare il modello a generalizzare.

2.2. Modellazione e Interpretazione

- 52 **Training:** Dopo aver diviso il dataset, addestrare modelli di classificazione come **Logistic Regression** e **LightGBM** (una variante di Gradient Boosting molto performante su dataset di grandi dimensioni).
- 53 **Valutazione:** Usare l'AUC come metrica principale per valutare la capacità del modello di distinguere tra prenotazioni confermate e cancellate.
- 54 **Interpretazione Approfondita:**
 - **Feature Importance:** Quali fattori indicano una prenotazione più "sicura"? Probabilmente un lead_time più breve e certi market_segment (es. gruppi vs viaggiatori individuali).
 - **Partial Dependence:** Analizzare come la probabilità di cancellazione cambia con l'aumentare del lead_time (anticipo della prenotazione). È probabile che più si prenota in anticipo, più alta sia la probabilità di cancellazione.
 - **What-If:** Simulare l'impatto di un aumento del lead_time di 10 giorni su una specifica prenotazione.

3. Consegna Finale

- **Flow Dataiku completo e ottimizzato.**
- **Dataset con le previsioni di probabilità di conferma.**
- **Una presentazione dettagliata che non solo descriva il modello, ma che proponga anche delle chiare strategie di business basate sulle scoperte fatte (es. "Per i clienti dal paese X con un lead time > 100 giorni, potremmo richiedere un piccolo deposito non rimborsabile per ridurre il rischio di cancellazione").**